

Отчёт по модулю «Кластеризация данных клиентов» (module04)

Репозиторий: <https://github.com/Teni-Moridera/module04>. Отдельный README в репозитории не заполнен; в корне есть файл тз.docx. Ниже — содержание по скрипту clustering_analysis.py, файлу данных PP13_ISP23V_clustering.csv и каталогу артефактов clustering_output/.

1. Цель модуля

Провести **кластерный анализ** набора признаков клиентов (возраст, доход, индекс трат, частота покупок): подготовить данные, оценить число кластеров, применить **k-means**, **иерархическую кластеризацию** и **DBSCAN**, оценить качество (**силуэт**), построить **визуализации** (РСА, тепловая карта корреляций, дендрограмма, метод локтя) и дать **интерпретацию сегментов** в терминах отклонений от средних по выборке.

2. Постановка задач (что требовалось сделать)

№	Задача	Смысл
1	Загрузить и очистить данные	Убрать дубликаты, пропуски, нефизичные значения признаков
2	Проанализировать корреляции признаков	Понять линейные связи перед кластеризацией
3	Нормализовать признаки	Сопоставимость масштабов для метрических методов
4	Выбрать число кластеров k	Метод локтя и силуэт для k-means
5	Обучить k-means и иерархическую модель	Сравнение подходов при одном k
6	Применить DBSCAN	Выявление плотных областей и шума
7	Визуализировать результаты	РСА в 2D, дендрограмма на подвыборке
8	Интерпретировать кластеры	Профили по средним и бизнес-формулировки
9	Сохранить графики в каталог	Воспроизводимые артефакты для отчёта

3. Что сделано и зачем

3.1. Данные и признаки

- Источник: CSV PP13_ISP23V_clustering.csv с полями customer_age, annual_income, spending_score, purchase_frequency_per_month.
- Очистка: удаление дубликатов и строк с пропусками, отбор записей с неотрицательными значениями по всем признакам.
- Масштабирование: StandardScaler перед расчётами расстояний и кластеризации.

Зачем: без выбросов по знаку и с единым масштабом k-means и иерархия на евклидовых расстояниях работают предсказуемо.

3.2. Корреляционный анализ

- Матрица корреляций по четырём признакам, вывод в консоль и тепловая карта `clustering_output/correlation_heatmap.png` (seaborn).

Зачем: понять избыточность и совместную вариацию признаков до сегментации.

3.3. Выбор k для k-means

- Для k от 2 до 10: инерция (WCSS) и средний силуэт по разметке k-means.
- «Локоть»: максимум расстояния от точек кривой инерции до хорды между первой и последней точкой.
- Итоговое k : если максимум силуэта не превышает силуэт при k из локтя более чем на 0.03 — берётся более простая модель (локоть), иначе — k по максимуму силуэта.
- График: `elbow_silhouette.png`.

Зачем: согласовать эвристики выбора числа кластерей и уменьшить переусложнение.

3.4. K-means и профили

- Обучение KMeans с `random_state=42`, `n_init="auto"`; вывод инерции и силуэта, таблица средних/стд/числа объектов по кластерам.
- Визуализация в первых двух главных компонентах PCA: `pca_kmeans.png`.

Зачем: базовая сегментация, хорошо интерпретируемая при близких сферических кластерах.

3.5. Иерархическая кластеризация

- AgglomerativeClustering с связью Ward и тем же k , что и для k-means; силуэт и профили; PCA-график `pca_hierarchical.png`.
- Дендрограмма на случайной подвыборке до 40 объектов: `dendrogram_sample.png` (scipy linkage).

Зачем: альтернативная иерархия для сравнения устойчивости сегментов.

3.6. DBSCAN

- Параметры: `eps=0.85`, `min_samples=5` в пространстве после масштабирования; подсчёт кластеров и точек шума (-1); при наличии ≥ 2 кластеров — силуэт без шумовых точек.
- PCA: `pca_dbscan.png`.

Зачем: обнаружить плотные группы и аномальные/переходные наблюдения без заданного k .

3.7. Интерпретация и рекомендации

- Для меток k-means: по каждому кластеру сравнение средних признаков с глобальными средними (порог $\sim 8\%$ отклонения для текстового описания).
- В консоль выводятся рекомендации: использовать сегменты в маркетинге, сверять с иерархией, анализировать шум DBSCAN отдельно, переобучать модель при обновлении данных.

Зачем: связать технику кластеризации с задачами персонализации и сопровождения модели.

3.8. Зависимости (requirements.txt)

- pandas, numpy, scikit-learn, matplotlib, seaborn, scipy (нижние границы версий указаны в файле).

4. Технологии и обоснование выбора

Технология	Зачем использована
Python 3	Стандарт для анализа данных и машинного обучения.
pandas / numpy	Загрузка CSV, очистка, работа с матрицей признаков.
scikit-learn	Масштабирование, KMeans, AgglomerativeClustering, DBSCAN, PCA, метрика силуэта.
scipy	linkage и dendrogram для иерархической визуализации.
matplotlib / seaborn	Графики локтя, силуэта, PCA, тепловая карта корреляций, оформление в стиле сетки.
PCA (2 компоненты)	Сжатие признаков для 2D-визуализации кластеров без обучения отдельной нейросети.

5. Краткий вывод

Модуль реализует **сквозной пайплайн** кластерного анализа клиентских данных: от очистки и масштабирования до **выбора k , трёх методов кластеризации, метрик качества и графического сопровождения**. Артефакты сохраняются в clustering_output/ (корреляции, локоть/силуэт, PCA для k-means, иерархии и DBSCAN, дендрограмма). Такой стек (Python + scikit-learn + визуализация) типичен для учебных и прикладных задач сегментации клиентской базы.